

PROMPT IA 07

Data Platform + CDC + Analytics

Debezium + Kafka Connect + Kafka + ClickHouse + dbt Core + DataHub + Superset

Mission : construire la plateforme Data OSS du projet e-commerce sans charger les PostgreSQL OLTP et sans coupler les microservices a leurs schemas SQL internes.

OSS-first - event-driven - data quality - lineage - reproducibilite - GitOps

1. Role de l'IA

Tu es Lead Data Platform Engineer. Implemente une plateforme analytique self-hosted, reproductible et observable dans le monorepo/infrastructure existants. Travaille par increments, teste chaque etape et factorise les configurations communes.

Ne remplace jamais les evenements metier Outbox par du CDC brut. Le CDC transporte des changements techniques ; les contrats inter-microservices restent les evenements metier versionnes.

2. Architecture cible

```
PostgreSQL OLTP
|
+--> Outbox --> Kafka --> business consumers
|
+--> WAL --> Debezium / Kafka Connect
|
v
Kafka
|
v
ClickHouse
|
dbt Core
|
analytics marts
|
Superset

Metadata / lineage:
PostgreSQL + Kafka + ClickHouse + dbt + Superset
|
v
DataHub
```

3. Separation des responsabilites

Composant	Responsabilite
PostgreSQL	Source de verite OLTP par microservice.
Outbox + Kafka	Evenements metier durables et integration inter-services.
Debezium + Kafka Connect	CDC cible depuis PostgreSQL WAL vers Kafka/Data.
ClickHouse	Stockage analytique et BI lourde.
dbt Core	Transformations SQL, tests et marts versionnes.
DataHub	Catalogue, metadata, lineage, ownership et gouvernance.
Superset	Dashboards et exploration BI.

4. Debezium + Kafka Connect

Deployer Debezium/Kafka Connect de facon declarative. Configurer uniquement les bases/tables justifiees par un besoin Data ou un relay Outbox. Surveiller replication slots, WAL retention, connector lag, failed records et croissance disque PostgreSQL.

PostgreSQL WAL -> replication slot -> Debezium connector -> Kafka CDC -> ClickHouse

4.1 Regle de couplage

```
INTERDIT:
Order PostgreSQL -> CDC -> Inventory business logic

AUTORISE:
Order PostgreSQL -> CDC -> Kafka Data -> ClickHouse analytics

METIER:
Order Outbox -> order.confirmed.v1 -> consumers metier
```

5. Kafka Data

Utiliser des topics CDC distincts des topics metier. ACL explicites, schemas versionnes, retention documentee et replication.factor=3/min.insync.replicas=2.

```
business.order.confirmed.v1
cdc.order.orders.v1
cdc.payment.transactions.v1
data.sales.normalized.v1
```

6. ClickHouse

Creer staging et marts selon les cas d'usage, pas une copie aveugle des bases. Definir partitionnement, ORDER BY, TTL et materialized views apres analyse des requetes.

```
Kafka/CDC -> ClickHouse staging -> dbt
+> sales_daily
+> product_performance
+> conversion_funnel
+> payment_metrics
+> shipping_metrics
```

7. dbt Core

```
models/
staging/
intermediate/
marts/
sales/
product/
customer/
operations/
tests/
macros/
```

Versionner models, sources, tests et docs. Ajouter not_null, unique, relationships, accepted_values et tests metier. Factoriser seulement les transformations reellement reutilisables.

8. Data Quality-as-Code

```
dataset: sales_daily
owner: data-team
freshness: < 5 min
pii: none
tests:
- order_id unique
- amount >= 0
- currency not null
```

Chaque dataset important declare owner, source, schema, freshness SLA, classification PII, retention et quality rules.

9. DataHub

DataHub est la metadata platform officielle. Integrer Kafka, PostgreSQL, ClickHouse, dbt et Superset et exposer le lineage complet.

```
Order Service -> order.confirmed.v1 -> ClickHouse -> dbt sales_daily -> Superset
|
DataHub lineage
```

Backstage reste le catalogue services/APIs/runbooks ; DataHub catalogue datasets/schemas/lineage/qualite.

10. Superset

Deployer Superset self-hosted avec connexions Data read-only. Creer des dashboards de reference : ventes, panier moyen, conversion, paiements, retours, transporteurs et catalogue. Aucun dashboard lourd sur PostgreSQL OLTP.

11. Securite et PII

Appliquer minimisation, RBAC, masking et retention-as-code. Secrets via OpenBao, humains via Keycloak, workloads via identites dediees. Ne recopier aucune PII sans finalite analytique documentee.

12. Observabilite

```
debezium_connector_lag
postgres_wal_retained_bytes
replication_slot_lag
kafka_consumer_lag
clickhouse_insert_errors
clickhouse_query_latency
dbt_test_failures
dataset_freshness_seconds
data_quality_failures_total
superset_query_latency
```

Metrics Prometheus/Thanos, logs/traces dans la stack existante. Alertes sur lag, freshness, erreurs et indisponibilite.

13. Reconciliation

Ajouter des jobs de reconciliation source-vers-analytics pour detecter pertes, doublons et derives. Pipelines idempotents et rejouables.

```
Source count/checksum -> reconciliation
+--> MATCH: OK
+--> MISMATCH: alert + repair/replay
```

14. Tests obligatoires

Test	Attendu
CDC insert/update/delete	Evenements techniques produits correctement.
Connector restart	Reprise sans perte.
Kafka replay	Reconstruction analytique reproductible.
ClickHouse ingestion	Deduplication/idempotence conformes au modele.
dbt tests	Contraintes Data et metier verifiees.
Freshness SLA	Pipeline en retard detecte.
PII	Donnees interdites absentes ou masquees.
Lineage	Source -> Kafka -> ClickHouse -> dbt -> Superset visible dans DataHub.

15. CI/CD + GitOps

Versionner connectors, topics, schemas/migrations ClickHouse, dbt, recipes DataHub et configuration exportable Superset. Pipeline : lint -> tests -> integration -> security scan -> OCI -> SBOM -> Cosign -> Harbor -> FluxCD.

16. Ordre d'implementation

1. Security / secrets / network policies
2. Kafka Connect + Debezium minimal
3. Un pipeline PostgreSQL -> Kafka CDC
4. ClickHouse staging
5. dbt staging + mart
6. Superset dashboard
7. DataHub metadata + lineage
8. Data quality + freshness
9. Reconciliation
10. Observability
11. Replay/failure tests
12. GitOps + runbooks

17. Vertical slice Data initial

```
Order PostgreSQL
-> Debezium
-> Kafka CDC
-> ClickHouse staging
-> dbt Core
-> sales_daily
-> Superset Sales Dashboard
```

DataHub affiche le lineage complet.

Le slice doit etre restructurable depuis Git apres suppression volontaire des projections analytiques.

18. Definition of Done

- Debezium capture un flux PostgreSQL cible.
- Kafka transporte le CDC sans melange avec les contrats metier.
- ClickHouse repond aux requetes analytiques.
- dbt construit au moins un mart teste.
- Superset affiche un dashboard fonctionnel.
- DataHub expose metadata, ownership et lineage de bout en bout.
- Freshness, qualite, replay et tests de panne passent.
- Les PostgreSQL OLTP ne servent pas les dashboards lourds.
- L'ensemble est deployable par CI/CD + FluxCD.

Commence par un seul vertical slice fonctionnel. Mesure, teste, corrige et factorise avant de multiplier les connectors.